RELATÓRIO PARCIAL DE ATIVIDADES DE INICIAÇÃO CIENTÍFICA
Programa PIBIC-Af / Cadastro ICT

1 IDENTIFICAÇÃO

Centro: Centro de Ciências Exatas e de Tecnologia (CCET)

Departamento: Departamento de Computação (DC)

Orientador: Prof. Dr. Murilo Naldi

Aluno(a): Maylon Martins de Melo

Título do Projeto: Desenvolvimento e Melhoria do MustaCHE através do CORE-SG

Período de Vigência: Setembro/2025 a Agosto/2026

2 INTRODUÇÃO

O objetivo central deste projeto de Iniciação Científica é aprimorar a eficiência computacional da ferramenta MustaCHE (*Multiple Cluster Hierarchies Explorer*) através da integração do algoritmo CORE-SG. O software original, embora cientificamente relevante, encontrava-se em estado de obsolescência tecnológica (desenvolvido em Python 2.7 e Java), o que dificultava sua manutenção e execução em ambientes modernos.

Os objetivos específicos para este primeiro período foram:

- Realizar a reengenharia completa da plataforma (*MustaCHE v2*);
- Modernizar a *stack* tecnológica para Python 3.11, Flask e Plotly.js;
- Implementar containerização via Docker para garantir reprodutibilidade;
- Restaurar e validar as funcionalidades legadas (HAI Matrix, Meta-Clustering) antes da integração do CORE-SG.

3 RESUMO DAS ATIVIDADES E RESULTADOS OBTIDOS

Durante o período relatado, as atividades concentraram-se na reconstrução da arquitetura do sistema. A metodologia adotada focou na modularização e escalabilidade. Os principais resultados incluem:

1. **Reengenharia do Backend**: Migração integral do código legado para Python 3.11. Removeu-se a dependência de componentes Java, centralizando a lógica de clustering na biblioteca *scikit-learn* com o algoritmo HDBSCAN.
2. **Interface Gráfica Interativa**: Desenvolvimento de um novo *dashboard* utilizando Plotly.js, capaz de renderizar simultaneamente Dendrogramas, Matrizes de Similaridade HAI e *Reachability Plots* interativos (Figura 1).

3. **Containerização**: Criação de um ambiente Docker multi-estágio que automatiza a compilação de módulos Cython e a instalação de dependências científicas, garantindo que a ferramenta funcione de forma idêntica em qualquer plataforma.

4. **Implementação da Matriz HAI**: Restauração do cálculo do *Hierarchy Agreement Index* (Figura 3), essencial para comparar diferentes hierarquias de cluster e identificar a estabilidade dos parâmetros fundamentais do HDBSCAN (m_{pts}).

5. **Visualização Hierárquica (Dendrograma)**: Desenvolvimento de um componente interativo que permite visualizar a estrutura de agrupamento e realizar cortes dinâmicos ("thresholds") para a definição de meta-clusters (Figura 4).

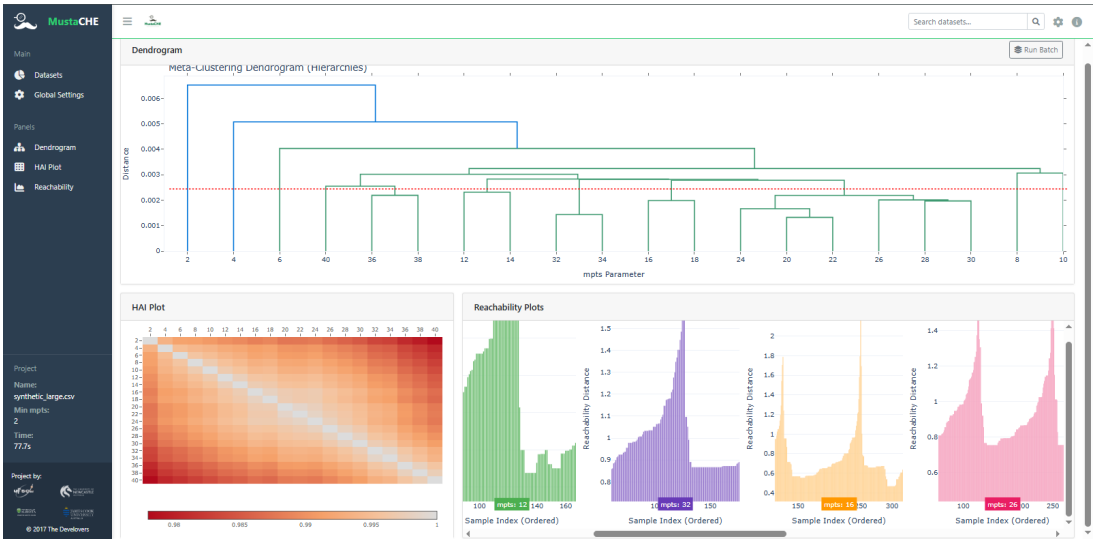

Figura 1: Interface principal do MustaCHE v2 com resultados de processamento em lote.

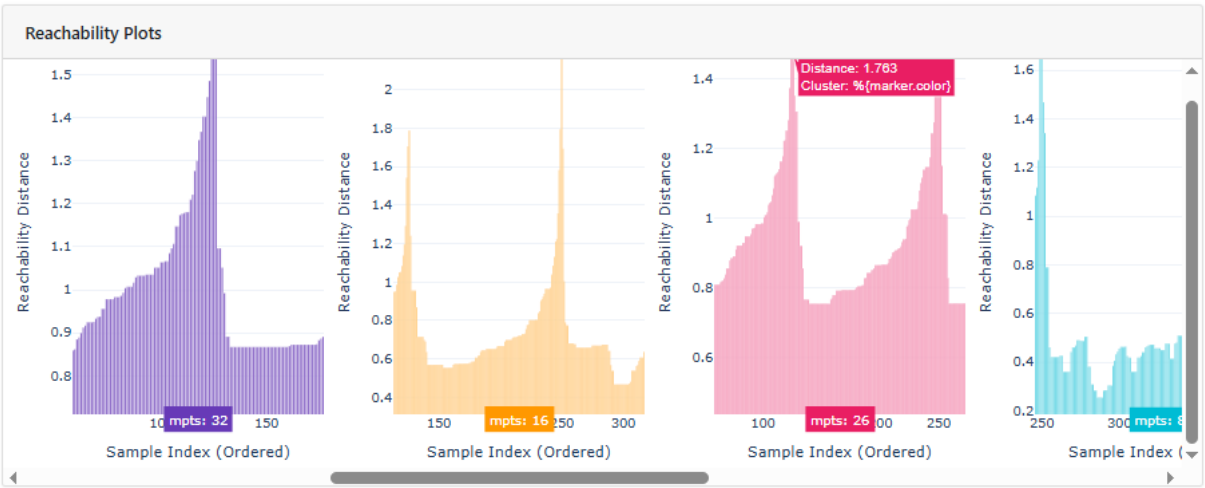

Figura 2: Visualização de Reachability Plots interativos no sistema modernizado.

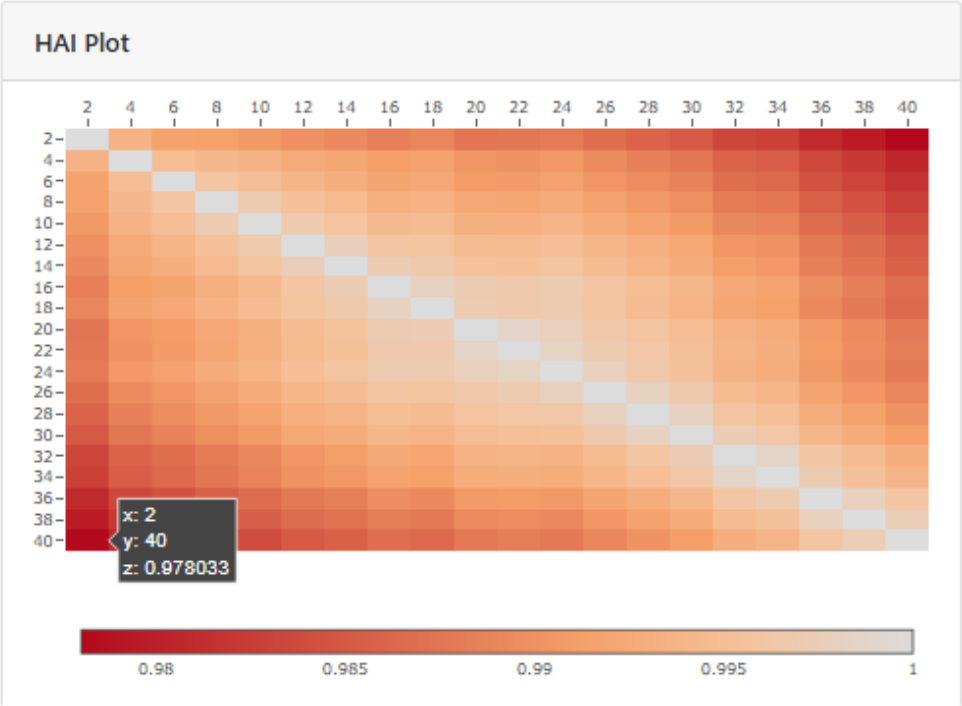

Figura 3: Matriz de Similaridade HAI, permitindo a análise de estabilidade das hierarquias geradas.

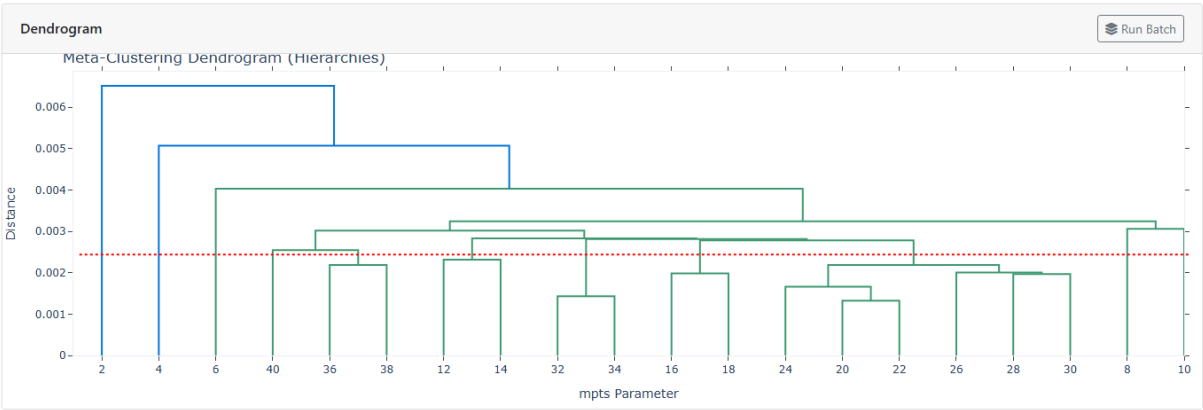

Figura 4: Dendrograma de Meta-Clusters com funcionalidade de seleção dinâmica de medoids.

4 DIFERENCIAIS TÉCNICOS E CIENTÍFICOS

Para além da reconstrução funcional, o projeto introduziu melhorias críticas no fluxo de trabalho científico da ferramenta:

1. **Reprodutibilidade Científica via Docker**: O uso de containerização de múltiplos estágios automatiza a compilação de módulos legados em Cython. Isso elimina a barreira do "funciona na minha máquina", permitindo que qualquer pesquisador reproduza as análises independentemente do sistema operacional utilizado.

2. **MustaCHE como Biblioteca Python**: O software foi reestruturado para ser não apenas um utilitário web, mas um pacote Python instalável. Isso permite que outros cientistas de dados importem suas funções (ex: `"from mustache.core import run_clustering"`) em seus próprios fluxos de trabalho de pesquisa via *Jupyter Notebooks* ou scripts, aumentando significativamente o impacto acadêmico da ferramenta.

3. **Padronização e Metadados de Citação**: Implementou-se o suporte ao formato *Citation File Format* (`CITATION.cff`) no repositório GitHub. Isso permite que a ferramenta seja automaticamente citable no GitHub e em serviços como o *Zenodo*, garantindo que o crédito acadêmico seja atribuído corretamente aos autores originais (Neto et al., 2018).

5 PRODUÇÃO TÉCNICO-CIENTÍFICA

As atividades desenvolvidas resultaram na criação de um repositório de código aberto no GitHub (`https://github.com/Maylon-hub/mustache`), estruturado com licença **BSD 3-Clause**. Esta licença foi escolhida por ser o padrão ouro do ecossistema científico Python (*NumPy*, *scikit-learn*), permitindo o uso acadêmico e comercial livre, enquanto protege os nomes dos autores originais e da UFSCar. Além do código-fonte, o repositório contém a documentação técnica necessária para reprodução integral dos experimentos.

6 CRONOGRAMA E PRÓXIMOS PASSOS

Para o restante do período de vigência da bolsa, o plano de trabalho foca na **Fase 2: Otimização e Comparação**. O diferencial desta etapa será a avaliação quantitativa do algoritmo CORE-SG em comparação ao HDBSCAN padrão, utilizando métricas como o índice **DBCV (Density-Based Clustering Validation)** e o tempo de execução (*throughput*) em conjuntos de dados de larga escala.

Tabela 1: Cronograma de atividades para os próximos seis meses.

Mês	**Atividade Planejada**
Mês 7-8	Integração do CORE-SG e refatoração do grafo de similaridade.
Mês 9-10	Bateria de experimentos comparativos e coleta de métricas (DBCV, Tempo).
Mês 11	Análise estatística dos resultados e escrita do relatório final.
Mês 12	Submissão de resultados a eventos científicos/periódicos (ex: Congresso de IC).

7 AUTO-AVALIAÇÃO ASSINADA

Avalio minha participação neste primeiro período como produtiva e de grande aprendizado técnico. A superação dos desafios de obsolescência do código original exigiu o domínio de ferramentas modernas de desenvolvimento (Docker, Flask, Git) e uma compreensão profunda da lógica matemática do HDBSCAN e do índice HAI. Sinto-me tecnicamente preparado para iniciar a integração do algoritmo CORE-SG na próxima fase do projeto.

Maylon Martins de Melo
Aluno(a)

8 AVALIAÇÃO DO(A) ORIENTADOR(A) ASSINADA

O orientado superou os atrasos iniciais do projeto demonstrando grande proatividade e capacidade técnica. A versão inicial do MustaCHE ainda não possui todas as funcionalidades da ferramenta original e só agora dispomos da nova versão do CORE-SG para integração. No entanto, decidimos pivotar a estratégia: acreditamos ser mais vantajoso investir o esforço de pesquisa no desenvolvimento de uma solução distribuída em Python, visando alcançar um público maior devido à popularidade da linguagem.

gov.br Documento assinado digitalmente
MURILO COELHO NALDI
Data: 24/03/2026 14:51:32-0300
Verifique em https://validar.iti.gov.br

Prof. Dr. Murilo Naldi
Orientador(a)